

第二章

条件期望和线性投影

Outline

- 1 条件期望
- 2 条件方差
- 3 线性投影

条件期望的定义

令 \mathbf{X} 为 K 维随机向量, Y 为一元随机变量。以 \mathbf{X} 为条件, Y 的条件期望函数 (Conditional Expectation Function, CEF) 定义如下:

$$\mu(\mathbf{X}) = \mathbb{E}(Y | \mathbf{X}) = \begin{cases} \int_Y y \cdot f(y | \mathbf{X}) dy, & Y \text{ 连续,} \\ \sum_Y y \cdot \mathbb{P}_{Y|\mathbf{X}}(y | \mathbf{X}), & Y \text{ 离散,} \end{cases}$$

其中, $f(y | \mathbf{X})$ 是以 \mathbf{X} 为条件 $Y = y$ 的条件概率密度函数, $\mathbb{P}_{Y|\mathbf{X}}(y | \mathbf{X})$ 是以 \mathbf{X} 为条件 $Y = y$ 的条件概率。

条件期望的性质

简单迭代期望律 (Simple Law of Iterated Expectations, SLIE)

若 $\mathbb{E}|Y| < \infty$, 则对任意的随机向量 \mathbf{X} , 我们有:

$$\mathbb{E}_{\mathbf{X}}[\mathbb{E}[Y \mid \mathbf{X}]] = \mathbb{E}[Y],$$

其中, 符号 $\mathbb{E}_{\mathbf{X}}[\cdot]$ 表示相对于随机向量 \mathbf{X} 求期望。

证明.

假设 Y 和 X 的联合概率密度函数为 $f(y, x)$, 因为 $\mathbb{E}[Y | X]$ 是 X 的函数, 我们有:

$$\mathbb{E}[\mathbb{E}[Y | X]] = \int_{\mathbb{R}^K} \mathbb{E}[Y | X = x] \cdot f_X(x) dx.$$

将 Y 为连续随机变量情况下条件期望的定义代入上式得到:

$$\begin{aligned} & \int_{\mathbb{R}^K} \left(\int_{\mathbb{R}} y f(y | x) dy \right) f_X(x) dx = \int_{\mathbb{R}^k} \int_{\mathbb{R}} y f(y, x) dy dx \\ &= \int_{\mathbb{R}} y f_Y(y) dy = \mathbb{E}[Y], \end{aligned}$$

其中, 第一个等号成立是因为 $f(y | x) f_X(x) = f(y, x)$; 第二个等号成立是因为联合分布和边缘分布之间存在如下关系:

$$\int_{\mathbb{R}^K} f(y, x) dx = f_Y(y).$$



迭代期望律

若 $\mathbb{E}|Y| < \infty$, 则对任意的随机向量 X_1 和 X_2 , 我们有:

$$\mathbb{E}_{X_1}[\mathbb{E}[Y \mid X_1, X_2] \mid X_1] = \mathbb{E}[Y \mid X_1].$$

实际上, 可以证明如下更一般形式的迭代期望律: 令 W 为随机向量, X 是随机向量且满足 $X = g(W)$ 。¹ 一般形式的 LIE 可表示为:

$$\mathbb{E}[Y \mid X] = \mathbb{E}[\mathbb{E}(Y \mid W) \mid X].$$

“The smaller information set always dominates.”

¹ 如果已知 W 的实现值, X 的实现值便是已知的。

CEF 分解性质

对任意的随机变量 Y ，有如下性质成立：

$$Y = \mathbb{E}[Y \mid \mathbf{X}] + \varepsilon, \quad (1)$$

其中，

- (a) ε 均值独立于 \mathbf{X} ，即 $\mathbb{E}[\varepsilon \mid \mathbf{X}] = 0$ ；
- (b) ε 与 \mathbf{X} 的任意函数都不相关。

证明.

首先证明 (a),

$$\mathbb{E}[\varepsilon \mid \mathbf{X}] = \mathbb{E}\{Y - \mathbb{E}[Y \mid \mathbf{X}] \mid \mathbf{X}\} = \mathbb{E}[Y \mid \mathbf{X}] - \mathbb{E}[Y \mid \mathbf{X}] = 0.$$

其次证明 (b), 假设 $h(\mathbf{X})$ 是 \mathbf{X} 的任意函数, 我们有:

$$\begin{aligned} \text{Cov}[\varepsilon, h(\mathbf{X})] &= \mathbb{E}[\varepsilon \cdot h(\mathbf{X})] - \mathbb{E}(\varepsilon)\mathbb{E}[h(\mathbf{X})] \\ &= \mathbb{E}\{\mathbb{E}[\varepsilon \cdot h(\mathbf{X}) \mid \mathbf{X}]\} - 0 \cdot \mathbb{E}[h(\mathbf{X})] \\ &= \mathbb{E}\{h(\mathbf{X}) \cdot \mathbb{E}[\varepsilon \mid \mathbf{X}]\} \\ &= 0. \end{aligned}$$



CEF 预测性质

假设 $\mathbb{E}(Y^2) < \infty$, \mathbf{X} 为 K 维随机向量, 记 $\mu(\mathbf{X}) \equiv \mathbb{E}(Y \mid \mathbf{X})$, 则 μ 是如下优化问题的解:

$$\min_{m(\mathbf{X})} \mathbb{E}[(Y - m(\mathbf{X}))^2],$$

其中, $m: \mathbb{R}^K \rightarrow \mathbb{R}$ 满足 $\mathbb{E}[m(\mathbf{X})^2] < \infty$ 。我们称 $\mathbb{E}[(Y - m(\mathbf{X}))^2]$ 为 $m(\mathbf{X})$ 预测 Y 时的均方误差 (mean squared error, MSE)。

条件方差

令 \mathbf{X} 为随机向量, Y 为一元随机变量。如果 $\mathbb{E}[Y^2] < \infty$, 以 $\mathbf{X} = \mathbf{x}$ 为条件, Y 的条件方差 (Conditional Variance) 定义如下:

$$\sigma^2(\mathbf{x}) = \text{Var}[Y \mid \mathbf{X} = \mathbf{x}] = \mathbb{E} \left[(Y - \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}])^2 \mid \mathbf{X} = \mathbf{x} \right].$$

条件方差作为随机变量 \mathbf{X} 的函数可记为 $\sigma^2(\mathbf{X})$ 。

方差分解

若 $\mathbb{E}[Y^2] < \infty$, 则有:

$$\text{Var}[Y] = \text{Var}[\mathbb{E}[Y \mid \mathbf{X}]] + \mathbb{E}[\text{Var}[Y \mid \mathbf{X}]].$$

证明.

根据 CEF 分解性质, 我们有:

$$\text{Var}[Y] = \text{Var}\{\mathbb{E}[Y | \mathbf{X}] + \varepsilon\}.$$

根据 CEF 分解性质中的 (b),

$$\text{Var}\{\mathbb{E}[Y | \mathbf{X}] + \varepsilon\} = \text{Var}[\mathbb{E}(Y | \mathbf{X})] + \text{Var}(\varepsilon).$$

现只需证明: $\text{Var}(\varepsilon) = \mathbb{E}[\text{Var}(Y | \mathbf{X})]$ 。事实上, 根据 CEF 分解性质中的 (a) 和 SLIE, $\mathbb{E}(\varepsilon) = 0$ 。于是, 我们有:

$$\begin{aligned} \text{Var}(\varepsilon) = \mathbb{E}(\varepsilon^2) &= \mathbb{E}[\mathbb{E}(\varepsilon^2 | \mathbf{X})] \\ &= \mathbb{E}\left\{\mathbb{E}\left[(Y - \mathbb{E}(Y | \mathbf{X}))^2 | \mathbf{X}\right]\right\} \\ &= \mathbb{E}[\text{Var}(Y | \mathbf{X})], \end{aligned}$$

其中, 第二个等号成立用到了 SLIE; 第三个等号成立用到了 $\varepsilon = Y - \mathbb{E}(Y | \mathbf{X})$; 最后一个等号成立用到了条件方差的定义。 □

线性投影

- 虽然条件期望 $\mu(X)$ 提供了 Y 的最优预测，但是 $\mu(X)$ 的函数形式通常是未知的。
- 在实证分析时，一般假设 CEF 具有线性形式，但是这种假设往往不切实际。更准确的做法是将线性形式的函数设定看作是 CEF 的近似。

线性投影

令 X 为随机向量。以 X 为条件，关于 Y 的最优线性预测，也称为线性投影，被定义为：

$$\mathcal{P}(Y | X) = X'\beta,$$

其中， β 被称为线性投影系数，也称为总体回归系数，它最小化如下均方预测误差：

$$S(b) = \mathbb{E}((Y - X'b)^2).$$

$S(b)$ 的最小化问题也被称为总体最小二乘 (population least squares) 问题。

线性投影的性质

- (1) 线性投影系数 β 存在且唯一，其表达式为：

$$\beta = (\mathbb{E}[X X'])^{-1} \mathbb{E}[X Y].$$

- (2) 投影误差 $e = Y - X'\beta$ 满足 $\mathbb{E}[e^2] < \infty$ 和 $\mathbb{E}[X e] = 0$ 。特别地，若 X 中含有常数项，则 $\mathbb{E}(e) = 0$ 。 $\mathbb{E}[X e] = 0$ 被称为 X 与 e 正交。

线性投影与 CEF

- (1) 假设 CEF 是 X 的线性函数, 则 $\mu(X) = \mathcal{P}(Y | X)$.
- (2) $\mathcal{P}(Y | X)$ 是关于 Y 的最小化 MSE 的最优线性预测。
- (3) $\mathcal{P}(Y | X)$ 是 CEF 的最优 (最小化 MSE) 线性近似, 即 β 是如下最优化问题的解:

$$\min_b \mathbb{E} \left\{ \left(\mathbb{E}[Y | X] - X'b \right)^2 \right\}.$$

考虑两种特殊情况：

- $\mathbf{X} = (1, X_1)'$ ，在此种情况下，我们有：

$$Y = \alpha + \beta_1 X_1 + e,$$

其中， α 和 β_1 分别是常数项 1 和 X_1 对应的线性投影系数。容易证明：

$$\beta_1 = \frac{\text{Cov}(Y, X_1)}{\text{Var}(X_1)}, \quad \alpha = \mathbb{E}(Y) - \beta_1 \mathbb{E}(X_1). \quad (2)$$

- $\mathbf{X} = (1, X_1, X_2, \dots, X_K)'$ ， $K > 1$ ，在此种情况下，我们有：

$$\beta_k = \frac{\text{Cov}(Y, \tilde{X}_k)}{\text{Var}(\tilde{X}_k)}, \quad (3)$$

其中， β_k 是 X_k 对应的线性投影系数， \tilde{X}_k 是 X_k 对 \mathbf{X} 中所有其他变量投影（包括常数项 1）得到的投影误差。

首先，将 Y 写成线性投影加投影误差的形式：

$$Y = \alpha + \beta_1 X_1 + \cdots + \beta_k X_k + \cdots + \beta_K X_K + e.$$

将上式代入 $\text{Cov}(Y, \tilde{X}_k)$ ，我们有：

- $\text{Cov}(\tilde{X}_k, e) = 0$ ，因为 \tilde{X}_k 是 X 各个分量的线性组合， e 与 X 不相关；
- $\text{Cov}(\tilde{X}_k, X_j) = 0, j \neq k$ ，因为 \tilde{X}_k 是线性投影误差，与 X_j 不相关；
- $\text{Cov}(\tilde{X}_k, X_k) = \text{Cov}(\tilde{X}_k, \tilde{X}_k + \mathbf{X}'_{-k}\beta_{-k}) = \text{Var}(\tilde{X}_k)$ ，其中， \mathbf{X}_{-k} 表示除 X_k 之外的所有协变量构成的向量，即 $\mathbf{X}_{-k} = (1, X_1, \dots, X_{k-1}, X_{k+1}, \dots, X_K)'$ ， β_{-k} 是 X_k 对 \mathbf{X}_{-k} 进行投影得到的线性投影系数。

于是，

$$\frac{\text{Cov}(Y, \tilde{X}_k)}{\text{Var}(\tilde{X}_k)} = \frac{\beta_k \text{Var}(\tilde{X}_k)}{\text{Var}(\tilde{X}_k)} = \beta_k.$$

References



Joshua D. Angrist & Jörn-Steffen Pischke (2009)

Mostly Harmless Econometrics: An Empiricist's Companion, Chapter 3.

Princeton University Press, 2009.



Bruce E. Hansen. (2020)

Econometrics, Section 2.18.

<https://www.ssc.wisc.edu/~bhansen/econometrics/>

▶ Link